# 实验 22: Linux 特定文件系统设计探析

计科 1903 班 19281171 王雨潇

# 1. 实验目的

探索、分析、理解并掌握 Linux 内核关于特定文件系统的功能支撑设计原理、实现机制和编程要旨。

# 2. 实验环境

编译环境:GNU 编译器 GCC-1.4.0,汇编器 as86,链接器 ld86

运行环境: Bochs-2.2.1 虚拟机, Intel x86 计算机模拟器

测试环境: Bochs-2.2.1 虚拟机和附带的 bochsdbg 调试器

宿主机: 操作系统 Windows 10 家庭版, CPU Intel Core i7-10710 (x86-64 架构)

该实验报告使用 Plantuml 绘制全部流程图,源码截图使用 VS Code

# 3. 实验内容

下载 Linux 内核源码,摘取和研读文件系统相关的源程序。

围绕某一特定文件系统(譬如 EXT、FAT 或 NTFS)的功能支撑设计原理,深入分析和理解文件操作相关系统调用、内核实现机制、对应文件系统标准规范暨数据结构描述等。

完成该 Linux 内核源码的编译、加载和启用,并通过运行特定命令或程序测试验证自己的分析结果。

# 目录

实验 22:	Linux 特定文件系统设计探析	.1
1.	实验目的	.1
2	实验环境	1
3.	实验内容	.1
4.	实验流程	.3
	4.1. MINIX 文件系统设计简析	.3
	4.2. Linux-0.11 文件系统实现机制	.4
	4.2.1. 文件系统低层设计	.4
	4.2.2. 高速缓冲区机制	.6
	4.2.3. 文件数据操作	.9
	4.2.4. 文件系统调用接口	l C
	4.3. Linux-0.11 内核编译启用	14
	4.4. 验证分析结果	16
5.	实验结论和心得体会	17

# 4. 实验流程

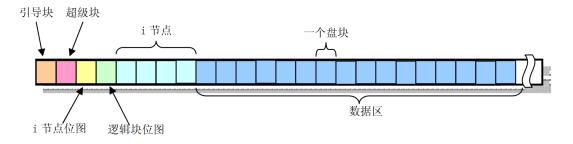
从官网下载并解压一份 devel 开发者版本 (包含 include) 的 Linux-0.11 内核源码,用于阅读;

Linux-0.11 内核的文件系统主要实现集中在\fs\目录下,可以分为 4 个模块:

模块	主要源码文件	功能		
高速缓冲区管理程序	buffer.c	实现对硬盘等块设备进行数据高速存取		
	bitmap.c	实现文件索引节点的管理、磁盘数据块分配释放、		· 现 ·
   文件系统低层通用函数	inode.c			
文件系统似宏通用函数 	namei.c	文件名与i节点转换算法		
	super.c	文件有一、口点较快算点		
	block_dev.c	实现对各类文件的访问、读、写操作		
	file_dev.c			
文件数据操作	char_dev.c			
	pipe.c			
	read_write.c			
	open.c	实现文件打开、关闭、创建 以及文件目录的操作		
	exec.c			
文件系统调用接口	fcntl.c			
	ioctl.c			
	stat.c			

# 4.1. MINIX 文件系统设计简析

Linux-0.11 内核使用的文件系统为 1.0 版本的 MINIX 文件系统,与标准 UNIX 文件系统基本相同, 是采用**两级索引分配**结构的文件系统,每个文件或目录映射到一个 i 节点,根据目录逐级访问文件。



MINIX 文件系统 1.0 版本支持的最大块设备容量(长度)是 64MB。

#### 外存布局结构如上图所示,其中各部分作用如下:

- (1) 引导块是计算机加电启动时 ROM BIOS 自动读入的执行代码和数据;
- (2) 超级块负责存放盘设备上文件系统结构的信息,说明各部分的大小;
- (3) i 节点位图 每个 bit 代表一个 i 节点的使用情况;
- (4) 逻辑块位图 每个 bit 代表盘上数据区中的一个数据盘块的使用情况;
- (5) i 节点 部分存放文件系统中每一个文件或目录的索引节点,包括对应文件的相关信息;
- (6) 数据区 存放的是真正的文件数据;

# 4.2. Linux-0.11 文件系统实现机制

## 4.2.1. 文件系统低层设计

在 MINIX 文件系统中,一个文件名通过对应的 i 节点映射到磁盘块的相应数据。i 结点各字段信息的结构体定义在.\include\linux\fs.h 中,如下图所示:

```
93 struct m_inode {
94    unsigned short i_mode;
95    unsigned short i_uid;
96    unsigned long i_size;
97    unsigned long i_mtime;
98    unsigned char i_gid;
99    unsigned char i_nlinks;
100    unsigned short i_zone[9];
101    /* these are in memory also */
102    struct task_struct * i_wait;
```

m\_inode 的 i\_zone[9] 数组字段存放的就分别是文件的直接块号、一次间接块号、二次间接块号。而文件类型、权限信息分别保存在对应 i 节点的 i mode 字段高低位。

6 种文件类型分别是:正规文件、目录名 (Linux 内核中万物皆文件,目录也被认为是一种文件)、符号连接、命名管道、字符设备文件、块设备文件。

文件系统的底层设计即内核源码对 i 节点的直接存取操作功能部分,其中.\fs\bitmap.c 主要包括负责在释放和占用数据时修改 i 节点位图、和逻辑块位图使用状态的 4 个函数,如下图所示:

.\fs\inode.c 主要包括对 i 结点进行分配、释放、取内容的关键函数,这些函数内部通过定义在同一文件内的 wait\_on\_inode()、write\_inode()、read\_inode()、sync\_inodes() 等函数实现具体的底层操作,如下图所示:

.\fs\namei.c 的 struct m\_inode \* namei() 函数的输入参数是文件路径,返回值是 i 节点,其内部借助 inode.c 定义的 i 节点操作函数实现,如下图所示:

```
struct m_inode * namei(const char * pathname)
   const char * basename;
   int inr,dev,namelen;
   struct m_inode * dir;
    struct buffer_head * bh;
   struct dir_entry * de;
   if (!(dir = dir_namei(pathname,&namelen,&basename)))
       return NULL;
                            /* special case: '/usr/' etc */
   if (!namelen)
       return dir;
   bh = find_entry(&dir,basename,namelen,&de);
   if (!bh) {
       iput(dir);
       return NULL;
   inr = de->inode;
   dev = dir->i_dev;
   brelse(bh);
   iput(dir);
   dir=iget(dev,inr);
    if (dir) {
       dir->i_atime=CURRENT_TIME;
       dir->i_dirt=1;
    return dir;
```

.\fs\super.c 主要包括用于处理文件系统超级块的函数 get\_super()、put\_super()和 free\_super(),以及这些函数用到的底层中断、系统调用等功能。

# 4.2.2. 高速缓冲区机制

由于 I/O 操作开销较大,为提升操作系统内核性能,Linux-0.11 使用高速数据缓冲区作为用户进程和外存之间的中间层,高速缓冲区存放最近被使用的数据,每个缓冲块和磁盘数据块大小相等(均为 1024 字节),使用户进程对文件系统的任何访问操作都会先访问缓冲区,缓冲区未命中时再查找外存设备。

高速缓冲区的数据结构是:以 1024 字节(与外存的数据块大小相同)为最小单位,将整个缓冲区划分成小缓冲块,采用哈希表 hash\_table 和空闲缓冲块链表 free\_list 两种数据结构共同管理。这种组合方式的好处是,可以用哈希表实现 O(1)的缓冲头查询、用双向链表实现 O(1)插入和删除头尾结点。

buffer\_head 结构体的定义在.\include\linux\fs.h 中,如下图所示:

实际使用的缓冲头队列和表变量、以及对高速缓冲区进行操作的代码,主要集中在.\fs\buffer.c中。

```
extern int end;
struct buffer_head * start_buffer = (struct buffer_head *) &end;
struct buffer_head * hash_table[NR_HASH];
static struct buffer_head * free_list;
static struct task_struct * buffer_wait = NULL;
int NR_BUFFERS = 0;
```

.\fs\buffer.c 提供了 3 个高速缓冲区读取函数,分别是块读取函数 bread(),块提前预读函数 breada(),页块读取函数 bread page(),它们的共同功能都是调用对应的块读写函数,区别如下:

函数原型	行号	功能
struct buffer_head * bread(int dev,int block)	267	返回一个指定的缓存块
void bread_page(unsigned long address,	296	一次读取 4 块缓冲块到内存指定地址。
int dev,int b[4])		
struct buffer_head * breada(int dev,int first,)	322	返回指定设备读取指定的一些块

.\fs\buffer.c 还提供了缓冲区的同步方式。getblk()函数在获取缓冲块时,如果发现缓冲块 dirt 字段为 1 (即缓冲块有数据未同步到磁盘),就会调用 sync\_dev()函数将数据同步到硬盘。

如下图所示, sync dev()函数内部是调用 II rw block()将缓冲块数据写入磁盘的。

```
int sync_dev(int dev)
    int i;
    struct buffer_head * bh;
   bh = start_buffer;
    for (i=0; i<NR_BUFFERS; i++,bh++) {</pre>
        if (bh->b_dev != dev)
            continue;
        wait_on_buffer(bh);
        if (bh->b_dev == dev && bh->b_dirt)
            11 rw block(WRITE,bh);
    sync_inodes();
   bh = start buffer;
    for (i=0; i<NR_BUFFERS; i++,bh++) {</pre>
        if (bh->b_dev != dev)
            continue;
        wait_on_buffer(bh);
        if (bh->b_dev == dev && bh->b_dirt)
            11_rw_block(WRITE,bh);
    return 0;
```

.\fs\buffer.c 还包括缓冲区的置换方法,当调用 getblk()函数时,该函数会采用 LRU 算法,调用定义在同一文件下的 remove\_from\_queues()函数,从 hash 表中和空闲链表中移除要被清理的缓冲区。

```
static inline void remove_from_queues(struct buffer_head * bh)
{
   /* remove from hash-queue */
    if (bh->b_next)
        bh->b_next->b_prev = bh->b_prev;
    if (bh->b_prev)
        bh->b_prev->b_next = bh->b_next;
    if (hash(bh->b_dev,bh->b_blocknr) == bh)
        hash(bh->b_dev,bh->b_blocknr) = bh->b_next;

/* remove from free list */
    if (!(bh->b_prev_free) || !(bh->b_next_free))
        panic("Free block list corrupted");
    bh->b_prev_free->b_next_free = bh->b_next_free;
    bh->b_next_free->b_prev_free = bh->b_prev_free;
    if (free_list == bh)
        free_list = bh->b_next_free;
```

## 4.2.3. 文件数据操作

.\fs\目录下, block\_dev.c、file\_dev.c、char\_dev.c、pipe.c 这 4 个文件分别是块设备、字符设备、管道设备和普通文件的外部调用接口。其中 block\_dev.c、file\_dev.c、pipe.c 的读写函数大同小异,如下图所示:

```
14 int block_write(int dev, long * pos, char * buf, int count)
15 > {...
45 }
46
47 int block_read(int dev, unsigned long * pos, char * buf, int count)
48 > {...
73 }
17 int file_read(struct m_inode * inode, struct file * filp, char * buf, int count)
18 > {...
46 }
47
48 int file_write(struct m_inode * inode, struct file * filp, char * buf, int count)
49 > {...
56 > /*...
90 }
13 // inode: 管道对应的 i 节点, buf: 数据缓冲区指针, count: 读取的字节数。
14 int read_pipe(struct m_inode * inode, char * buf, int count)
15 > {...
40 }
41
42 int write_pipe(struct m_inode * inode, char * buf, int count)
43 > {...
70 }
71
72 int sys_pipe(unsigned long * fildes)
73 > {...
```

.\fs\read\_write.c 文件是字符设备文件(包括控制台终端 tty、串口终端 ttyx、内存字符设备)的读写函数,系统调用 read()和 write()的内部实现就是调用 char\_dev.c 中的 rw\_char()函数来操作。

```
int rw_char(int rw,int dev, char * buf, int count, off_t * pos)
{
    crw_ptr call_addr;
    if (MAJOR(dev)>=NRDEVS)
        return -ENODEV;
    if (!(call_addr=crw_table[MAJOR(dev)]))
        return -ENODEV;
    return call_addr(rw,MINOR(dev),buf,count,pos);
}
```

## 4.2.4. 文件系统调用接口

这部分代码是文件系统调用的对接上层功能的实现。

.\fs\open.c 中名称以 "sys " 开头的函数实现的都是文件的创建、打开和关闭,属性修改等系统调用。

.\fs\exec.c 中最关键的部分是 int do\_execve(unsigned long \* eip,long tmp,char \* filename, char

\*\* argv, char \*\* envp) 系统中断调用函数。第一步,它取得可执行程序的文件名对应的 i 节点号,如下图:

```
struct m_inode * inode;
struct buffer head * bh;
struct exec ex;
unsigned long page[MAX_ARG_PAGES];
int i,argc,envc;
int e uid, e gid;
int retval;
int sh_bang = 0;
unsigned long p=PAGE_SIZE*MAX_ARG_PAGES-4;
if ((0xffff & eip[1]) != 0x000f)
   panic("execve called from supervisor mode");
for (i=0 ; i<MAX_ARG_PAGES ; i++) /* clear page-table */</pre>
   page[i]=0;
return -ENOENT;
argc = count(argv);
envc = count(envp);
```

#### 第二步,检查当前进程对该可执行文件有没有执行权限;

```
restart_interp:
    if (!S_ISREG(inode->i_mode)) { /* must be regular file */
        retval = -EACCES;
        goto exec error2;
    i = inode->i_mode;
    e uid = (i & S ISUID) ? inode->i uid : current->euid;
   e_gid = (i & S_ISGID) ? inode->i_gid : current->egid;
   if (current->euid == inode->i_uid)
        i >>= 6;
    else if (current->egid == inode->i_gid)
        i >>= 3;
    if (!(i & 1) &&
        !((inode->i_mode & 0111) && suser())) {
        retval = -ENOEXEC;
        goto exec_error2;
    if (!(bh = bread(inode->i_dev,inode->i_zone[0]))) {
        retval = -EACCES;
        goto exec_error2;
    }
```

第三步,处理可执行文件的执行头,.\fs\exec.c 的 225-318 行都是这部分的解析和出错处理,此处不一一列举;

第四步,释放旧程序 i 节点,让进程的 executable 指向新程序 i 节点,为新执行程序准备进程堆栈,函数结束;

```
if (current->executable)
    iput(current->executable);
current->executable = inode;
for (i=0; i<32; i++)
    current->sigaction[i].sa_handler = NULL;
for (i=0; i<NR_OPEN; i++)
    if ((current->close on exec>>i)&1)
        sys_close(i);
current->close_on_exec = 0;
free_page_tables(get_base(current->ldt[1]),get_limit(0x0f));
free_page_tables(get_base(current->ldt[2]),get_limit(0x17));
if (last task used math == current)
    last_task_used_math = NULL;
current->used_math = 0;
p += change ldt(ex.a text,page)-MAX ARG PAGES*PAGE SIZE;
p = (unsigned long) create_tables((char *)p,argc,envc);
current->brk = ex.a_bss +
    (current->end data = ex.a data +
    (current->end_code = ex.a_text));
current->start_stack = p & 0xfffff000;
current->euid = e_uid;
current->egid = e_gid;
i = ex.a_text+ex.a_data;
while (i&0xfff)
    put_fs_byte(0,(char *) (i++));
eip[0] = ex.a_entry;
                           /* eip, magic happens :-) */
eip[3] = p;
return 0;
```

.\fs\fcntl.c 实现了文件控制系统调用 sys\_fcntl()和两个文件句柄复制系统调用 sys\_dup()和 sys\_

### dup2(), 主要用在文件的标准输入/输出重定向和管道操作中;

```
int sys_dup2(unsigned int oldfd, unsigned int newfd)
    sys_close(newfd);
    return dupfd(oldfd,newfd);
int sys_dup(unsigned int fildes)
    return dupfd(fildes,0);
}
int sys_fcntl(unsigned int fd, unsigned int cmd, unsigned long arg)
    struct file * filp;
    if (fd >= NR_OPEN || !(filp = current->filp[fd]))
        return -EBADF;
    switch (cmd) {
        case F_DUPFD:
            return dupfd(fd,arg);
        case F_GETFD:
            return (current->close_on_exec>>fd)&1;
        case F_SETFD:
            if (arg&1)
                current->close_on_exec |= (1<<fd);</pre>
```

.\fs\ioctl.c 文件实现了输入/输出控制系统调用 sys ioctl1(), 功能是对终端的 I/O 进行控制。

```
int sys_ioctl(unsigned int fd, unsigned int cmd, unsigned long arg)

struct file * filp;

int dev,mode;

if (fd >= NR_OPEN || !(filp = current->filp[fd]))

return -EBADF;

mode=filp->f_inode->i_mode;

if (!S_ISCHR(mode) && !S_ISBLK(mode))

return -EINVAL;

dev = filp->f_inode->i_zone[0];

if (MAJOR(dev) >= NRDEVS)

return -ENODEV;

if (!ioctl_table[MAJOR(dev)])

return ioctl_table[MAJOR(dev)](dev,cmd,arg);

46
}
```

.\fs\stat.c 文件用于实现取文件状态信息的系统调用 sys\_stat()和 sys\_fstat(),分别是利用文件名取信息和使用文件句柄(描述符)来取信息,如下图所示:

```
int sys_stat(char * filename, struct stat * statbuf)
{
    struct m_inode * inode;

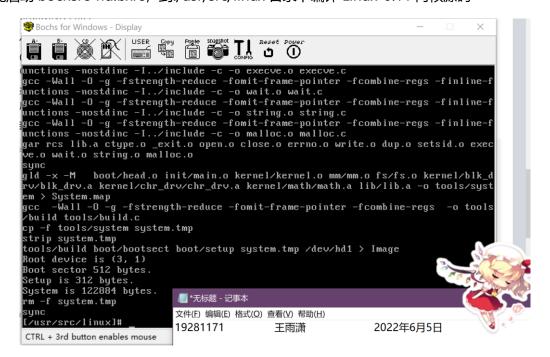
    if (!(inode=namei(filename)))
        return -ENOENT;
    cp_stat(inode,statbuf);
    iput(inode);
    return 0;
}

int sys_fstat(unsigned int fd, struct stat * statbuf)
{
    struct file * f;
    struct m_inode * inode;

    if (fd >= NR_OPEN || !(f=current->filp[fd]) || !(inode=f->f_inode))
        return -EBADF;
    cp_stat(inode,statbuf);
    return 0;
}
```

# 4.3. Linux-0.11 内核编译启用

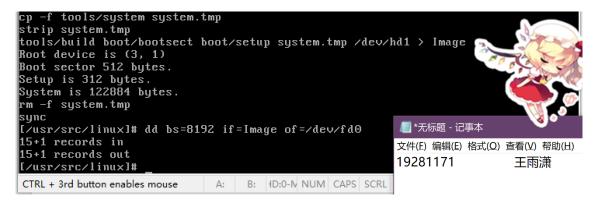
首先启动 bochsrc-hd.bxrc,到./usr/src/linux 目录下编译 Linux-0.11 内核源码



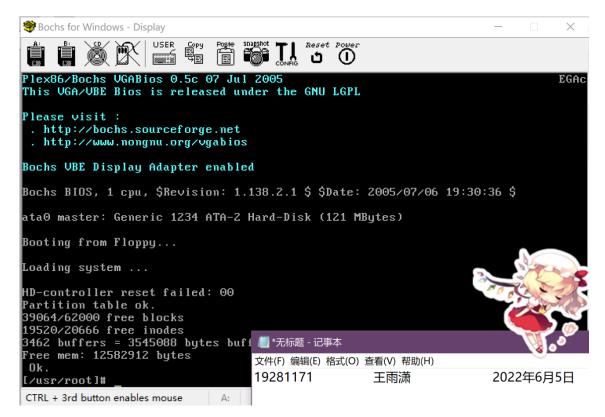
### 备份一份 bootimage-0.11-hd 命名为 bootimage-0.11-hd-copy, 备用;



### 输入命令 dd bs=8192 if=Image of=/dev/fd0, 把新的引导启动文件输出到 bootimage-0.11-hd;

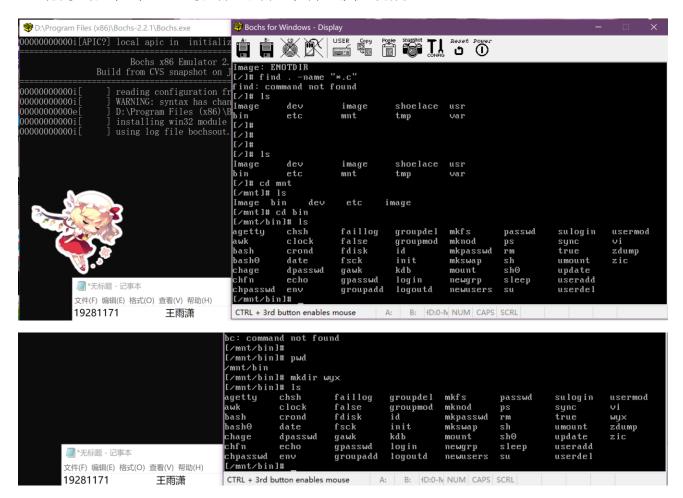


#### 按 Reset 重启模拟器, 截图如下所示:



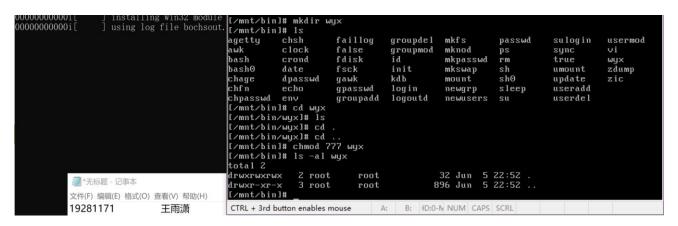
# 4.4. 验证分析结果

分别运行 ls, cd, mkdir 等文件目录管理命令, 截图如下所示:



再运行 chmod 777 命令修改文件权限,运行 ls -al 查看文件权限信息,可以发现文件夹 "wyx" 所

#### 有权限已被启用;



# 5. 实验结论和心得体会

在本次实验中,我通过阅读 Linux-0.11 的内核源码,了解了最初版本的 Linux 的文件系统设计实现机制,也巩固了课上所学的理论知识。阅读源码可以看出,Linux-0.11 作为最简操作系统,其内核的文件系统有着非常巧妙的层次结构。

作为用户程序和文件、目录、磁盘之间的抽象层,对于上层结构,Linux-0.11 的文件系统为用户封装了只需文件路径就可以操作 i 结点的接口,方便用户使用;对于底层结构,文件系统又分别实现了操作块设备(磁盘)、字符设备、管道、普通文件数据的方法,完成了文件管理的基本目标。我们应当熟悉Linux-0.11 内核中的文件管理实现,为以后编写出更好的程序打下基础。